

<좌표, 옥타브, DOG 번호>를 가진 keypoint를 검출한 후, 주변의 data에 맞게 미세 조정을 진행합니다. 이 정보들로 저조도로 인해 노이즈에 민감하거나 edge에 분포한 점들을 제거할 수 있습니다.

접근 방법론 중 하나는, interpolate된 최대점을 결정하기 위해 지역 sample point에 3D quadratic function을 적용해서 매칭과 안정성을 개선하는 것입니다.

Scale-space function $D(x, y, \sigma)$ 를 테일러 확장을 통해

$$D(x) = D + \frac{\partial D^T}{\partial x} x + \frac{1}{2} x^T \frac{\partial^2 D}{\partial x^2} x$$

로 변환시킵니다. 이 때 D 와 도함수들은 sample point에서 evaluate되고 $x = (x, y, \sigma)^T$ 는 이 점으로부터의 offset입니다. 일반적인 식의 극대, 극소를 구하는 것과 동일하게, x 의 극댓값

$$\hat{x} = -\frac{\partial^2 D^{-1}}{\partial x^2} \cdot \frac{\partial D}{\partial x}$$

는 위 함수의 미분값을 0으로 설정하여 결정합니다.

Hessian과 D 의 도함수들은 이웃한 sample point들의 차이를 이용하여 approximate됩니다. 3x3의 선형 시스템 결과는 최소 비용으로 해결될 수 있습니다. 만약 어떤 차원에서든 offset \hat{x} 가 0.5보다 크다면, 극댓값이 다른 sample point에 가깝다는 뜻입니다. 이 경우, sample point는 변하고 그 점 대신 interpolation이 수행됩니다. 최종 offset \hat{x} 는 지역 극점의 interpolate된 추정치를 얻기 위해 sample point의 지역에 추가됩니다. \hat{x} 를 $D(x)$ 에 대입한

$$D(\hat{x}) = D + \frac{1}{2} \frac{\partial D^T}{\partial x} \hat{x}$$

는 저조도의 불안정한 극점들을 제거하는데 유용합니다. (논문에서는, $|D(x)|$ 값이 0.03 미만이면 무시합니다.)

요약) 테일러 확장을 통해 좌표를 보정하고 저조도의 불안정한 극점을 제거합니다.

안정성을 위해서, 저조도 keypoint를 제거하는 것 만으로 충분하지 않습니다. DOG는 edge에 아주 강하게(민감하게) 반응하는데, edge 주변부, 즉 edge가 제대로 결정되지 않아 적은 양의 노이즈에도 불안정해도 마찬가지입니다.

poor하게 정의된 DOG의 극점^{peak}은 edge를 가로질러 큰 주곡률^{principal curvature}을 갖지만, 수직 방향의 (법선) 작은 주곡률을 가집니다. 주곡률은 keypoint의 location과 scale에서 계산된 2x2의 Hessian Matrix

$$H = \begin{bmatrix} D_{xx} & D_{xy} \\ D_{xy} & D_{yy} \end{bmatrix}$$

로 계산될 수 있습니다. D의 도함수는 이웃한 sample points의 차이를 이용해 추정됩니다.

H의 eigenvalue는 D의 주곡률에 비례합니다. 비율만 알면 되니까, eigenvalue를 명확하게 계산하지 않아도 됩니다. α 를 최대 eigenvalue, β 를 그보다 작은 것으로 가정하면, H의 trace로부터 eigenvalue의 합을, determinant로부터 H의 곱을 알 수 있습니다.

$$\text{Tr}(H) = D_{xx} + D_{yy} = \alpha + \beta$$

$$\text{Det}(H) = D_{xx}D_{yy} - (D_{xy})^2 = \alpha\beta$$

혹시라도 determinant가 음수라면, 곡률은 다른 sign을 가지고 따라서 point는 극점이 아닌 것으로 무시됩니다. $r = \beta/\alpha$ 라고 하면,


$$\frac{\text{Tr}(H)^2}{\text{Det}(H)} = \frac{(\alpha + \beta)^2}{\alpha\beta} = \frac{(r\beta + \beta)^2}{r\beta^2} = \frac{(r + 1)^2}{r}$$

이는 그들의 individual values보다는 오직 eigenvalue의 비율에만 의존합니다.

Quantity $(r + 1)^2/r$ 는 두 eigenvalue가 동일할 때 최소이고, r에 비례합니다. 따라서 주곡률의 비율이 임계값 r보다 낮은지 확인하기 위해선 위의 식만 확인하면 됩니다.

이것은 각각의 keypoint를 테스트하기 위해 요구되는 20자리 이하의 소수점 계산을 하기에 매우 효과적입니다. 논문에서의 실험은 $r=10$ 을 사용했는데, 10개 이상의 주곡률 사이의 keypoint를 제거합니다.

요약) edge 주변 keypoint 제거를 위해 H matrix의 eigenvalue의 비율, 즉 주곡률을 구합니다.



위의 그림은 keypoint 선택 과정입니다. (너무 지저분하게 많이 잡히는 것을 피하기 위해서, 저해상도의 이미지(233x189)를 사용하고, keypoint는 <좌표^{location}, 크기^{scale}, 방향^{orientation}>의 값을 가지는 벡터로 나타냈습니다.)

- (a) 원본
- (b) DOG의 검출된 극점 keypoint
- (c) 저조도 임계값^{threshold} 적용 후
- (d) 주곡률^{Principal curvatures} 임계값 적용 후 최종 결과